

Clases 4 y 5: OLS

Denise Laroze

5 de octubre de 2018

CESS - Universidad de Santiago
denise.laroze@usach.cl

Not so (Ordinary) Least Squares

Regresión Múltiple

Functional Form

Violaciones de supuestos - endogeneidad

Not so (Ordinary) Least Squares

1. Linearidad
2. Full Rank (relevante para regresiones múltiples)
3. Exogeneidad de covariables $E[\epsilon_i|X = 0]$. el valor esperado de las discrepancias o “errores” en la observación i no es una función de las covariables.
4. homoskedasticidad y no auto-correlación de los “errores”: Que ϵ_i tiene varianza constante y no está correlacionado con ninguna otra ϵ_j
5. Que los datos son generados exógenamente: el proceso de generación de los datos es externo a los supuestos del modelo, lo que implica que es externo a el/los procesos que generan ϵ . En otras palabras, **las covariables y los disturbios no están correlacionados.**
6. Los disturbios (“errores”) se distribuyen normalmente. Más específicamente $\epsilon|X \sim N(0, \sigma^2)$

$$\begin{aligned}b &= (X'X)^{-1}X'Y. \\&= (X'X)^{-1}X'(X\beta + \epsilon). \\&= (X'X)^{-1}(X'X)\beta + (X'X)^{-1}X'\epsilon. \\&= \beta + (X'X)^{-1}X'\epsilon.\end{aligned}$$

Take expected values over X .


$$E[b|X] = \beta + E[(X'X)^{-1}X'\epsilon|X].$$

$$E[b|X] = \beta.$$


Regresión Múltiple

$$Y = \alpha + \beta_1 X_1 + \beta_2 X_2 + \dots \beta_n X_n + \epsilon$$

Regresión lineal múltiple



Dummy variables




Regresión lineal múltiple

¿Cómo se interpretan los siguientes resultados?

	(1)	(2)
x1	0.112*** (0.006)	0.099*** (0.006)
x2	0.452*** (0.027)	0.525*** (0.027)
x3	1.472*** (0.125)	1.540*** (0.124)
factor(x4)1		6.041*** (0.280)
factor(x4)2		3.494*** (0.271)
factor(x4)3		0.165 (0.279)
factor(x4)4		4.146*** (0.360)
Constant	4.929*** (0.094)	4.750*** (0.259)
Observations	1,000	1,000
R ²	0.421	0.690
Adjusted R ²	0.419	0.687
F Statistic	241.250*** (df = 3; 996)	314.843*** (df = 7; 992)

Variables Categóricas



¿Cómo evaluar si una variable aporta a la explicación de la varianza de Y ?

¿Cómo evaluar si una variable aporta a la explicación de la varianza de Y ?

t-test

¿Cómo evaluar si una variable aporta a la explicación de la varianza de Y ?

t-test

¿Cómo saber si una variable categórica o conjunto de variables son un aporte al modelo de estimación o no?

¿Cómo evaluar si una variable aporta a la explicación de la varianza de Y?

t-test

¿Cómo saber si una variable categórica o conjunto de variables son un aporte al modelo de estimación o no?

F-test

$$F = \frac{(R_a^2 - R_0^2)/(k_a - k_0)}{(1 - R_a^2)/[n - (K_a + 1)]}$$

$$F = \frac{(R_{cambio}^2)/df_{cambio}}{(1 - R_a^2)/[n - (K_a + 1)]}$$

Donde R_a^2 corresponde al del modelo completo y R_0^2 al del modelo restringido.

La prueba de F sólo se puede hacer si el modelo restringido es un subconjunto del modelo completo.

$$1)y = \alpha + \beta_1x_1 + \beta_2x_2 + \beta_3x_3 + \beta_4x_4 + \epsilon$$

$$2)y = \alpha + \beta_1x_1 + \beta_2x_2 + \epsilon$$

$$3)y = \alpha + \beta_1x_1 + \beta_2x_2 + \beta_3x_3 + \beta_5x_5 + \epsilon$$

Comparar modelo 1) y 2) **Sí**, modelo 1) y 3) **NO**


Functional Form

Función real: $y < -5 + 1,3 * x1 - 0,05 * x1^2 + e$

	(1)	(2)
x1	0.869*** (0.026)	1.318*** (0.020)
I(x1^2)		-0.048*** (0.001)
Constant	1.373*** (0.278)	4.849*** (0.198)
Observations	1,000	1,000
R ²	0.530	0.811
Adjusted R ²	0.529	0.810
F Statistic	1,124.753*** (df = 1; 998)	2,136.135*** (df = 2; 997)

Note:

* p<0.1; ** p<0.05; *** p<0.01



Interacciones


Función real: $y < -5 + 0,1 * x_1 + 0,5 * x_2 + 1,5 * x_3 + -0,9 * x_2 * x_3 + e$

	(1)	(2)
x1	0.109*** (0.007)	0.112*** (0.006)
x2	-0.019 (0.030)	0.450*** (0.039)
x3	1.381*** (0.142)	1.471*** (0.125)
x2*x3		-0.897*** (0.053)
Constant	5.004*** (0.106)	4.929*** (0.094)
Observations	1,000	1,000
R ²	0.238	0.406
Adjusted R ²	0.235	0.403
Residual Std. Error	2.240 (df = 996)	1.979 (df = 995)
F Statistic	103.438*** (df = 3; 996)	169.846*** (df = 4; 995)


Note:

* p<0.1; ** p<0.05; *** p<0.01

Sin interacción - cuando existe



Con interacción - cuando existe



Efecto Marginal de X2

$$y < -\alpha + \beta_1 * x_1 + \beta_2 * x_2 + \beta_3 * x_3 + \beta_4 * x_2 * x_3 + e$$

$$y < -5 + 0,1 * x_1 + 0,5 * x_2 + 1,5 * x_3 - 0,9 * x_2 * x_3 + e$$

$$\frac{dE[y|x]}{dx_2} = 0,5 - 0,9 * x_3$$

Efecto Marginal de X2

$$y < -\alpha + \beta_1 * x_1 + \beta_2 * x_2 + \beta_3 * x_3 + \beta_4 * x_2 * x_3 + e$$

$$y < -5 + 0,1 * x_1 + 0,5 * x_2 + 1,5 * x_3 - 0,9 * x_2 * x_3 + e$$

$$\frac{dE[y|x]}{dx_2} = 0,5 - 0,9 * x_3$$

¿Pero cuál es la varianza de x_2 ? ¿Por qué importa?

Efecto Marginal de X2

$$y < -\alpha + \beta_1 * x1 + \beta_2 * x2 + \beta_3 * x3 + \beta_4 * x2 * x3 + e$$

$$y < -5 + 0,1 * x1 + 0,5 * x2 + 1,5 * x3 - 0,9 * x2 * x3 + e$$


$$\frac{dE[y|x]}{dx2} = 0,5 - 0,9 * x3$$

¿Pero cuál es la varianza de x2? ¿Por qué importa?

Delta method

$$Var(\beta_2 - \beta_4 * x3) = 1^2 + Var(\beta_2) + x3^2 + Var(\beta_4) + (2)(1)(x3)Cov(\beta_2, \beta_4)$$

Interpretación de multicolinealidad en diagrama de Ballentine



- El coeficiente β_j mide el efecto de X_j después de eliminar el efecto de todas las otras X sobre X_i . Es decir, el estimador MCO "depura" el efecto de X_i sobre Y , al eliminar la redundancia de la información que aportan otras variables.

Violaciones de supuestos - endogeneidad


Temas a considerar

Causalidad: $X \longrightarrow Y$


Causalidad inversa: $X \longleftarrow Y$

Simultaneidad: $X \longleftrightarrow Y$


Variables Omitidas:



Causalidad inversa



Omitted Variable Bias




$$Y = b_0 + b_1 X + e$$

$$Y = \beta_0 + \beta_1 X + \beta_2 Z + \varepsilon$$

$$b_1 \neq \beta_1$$

Omitted Variable Bias



$$b_1 \approx A + B$$

$$\beta_1 \approx A$$

$$bias \approx B$$

$$\beta_1 = b_1 - bias \approx (A + B) - B$$