

## Clase 4: OLS

---

Denise Laroze

28 de septiembre de 2018

CESS - Universidad de Santiago  
*denise.laroze@usach.cl*

Not so (Ordinary) Least Squares

Regresión Múltiple

Functional Form

Violaciones de supuestos - endogeneidad

## Not so (Ordinary) Least Squares

---

1. Linearidad
2. Full Rank (relevante para regresiones múltiples)
3. Exogeneidad de covariables  $E[\epsilon_i|X = 0]$ . el valor esperado de las discrepancias o “errores” en la observación  $i$  no es una función de las covariables.
4. homoskedasticidad y no auto-correlación de los “errores”: Que  $\epsilon_i$  tiene varianza constante y no está correlacionado con ninguna otra  $\epsilon_j$
5. Que los datos son generados exógenamente: el proceso de generación de los datos es externo a los supuestos del modelo, lo que implica que es externo a el/los procesos que generan  $\epsilon$ . En otras palabras, **las covariables y los disturbios no están correlacionados.**
6. Los disturbios (“errores”) se distribuyen normalmente. Más específicamente  $\epsilon|X \sim N(0, \sigma^2)$

$$\begin{aligned}b &= (X'X)^{-1}X'Y. \\&= (X'X)^{-1}X'(X\beta + \epsilon). \\&= (X'X)^{-1}(X'X)\beta + (X'X)^{-1}X'\epsilon. \\&= \beta + (X'X)^{-1}X'\epsilon.\end{aligned}$$

Take expected values over  $X$ .

$$E[b|X] = \beta + E[(X'X)^{-1}X'\epsilon|X].$$


$$E[b|X] = \beta.$$

# Regresión Múltiple

---


$$Y = \alpha + \beta_1 X_1 + \beta_2 X_2 + \dots \beta_n X_n + \epsilon$$

# Regresión lineal múltiple





# Dummy variables




# Regresión lineal múltiple

¿Cómo se interpretan los siguientes resultados?

	(1)	(2)
x1	0.112*** (0.006)	0.099*** (0.006)
x2	0.452*** (0.027)	0.525*** (0.027)
x3	1.472*** (0.125)	1.540*** (0.124)
factor(x4)1		6.041*** (0.280)
factor(x4)2		3.494*** (0.271)
factor(x4)3		0.165 (0.279)
factor(x4)4		4.146*** (0.360)
Constant	4.929*** (0.094)	4.750*** (0.259)
Observations	1,000	1,000
R <sup>2</sup>	0.421	0.690
Adjusted R <sup>2</sup>	0.419	0.687
F Statistic	241.250*** (df = 3; 996)	314.843*** (df = 7; 992)

# Variables Categóricas



# Functional Form


---

$$\text{Función real: } y < -5 + 1,3 * x_1 - 0,05 * x_1^2 + e$$

	(1)	(2)
x1	0.869*** (0.026)	1.318*** (0.020)
I(x1^2)		-0.048*** (0.001)
Constant	1.373*** (0.278)	4.849*** (0.198)
Observations	1,000	1,000
R <sup>2</sup>	0.530	0.811
Adjusted R <sup>2</sup>	0.529	0.810
F Statistic	1,124.753*** (df = 1; 998)	2,136.135*** (df = 2; 997)

Note:

\* p<0.1; \*\* p<0.05; \*\*\* p<0.01



# Interacciones


Función real:  $y < -5 + 0,1 * x_1 + 0,5 * x_2 + 1,5 * x_3 + -0,9 * x_2 * x_3 + e$

	(1)	(2)
x1	0.109*** (0.007)	0.112*** (0.006)
x2	-0.019 (0.030)	0.450*** (0.039)
x3	1.381*** (0.142)	1.471*** (0.125)
x2*x3		-0.897*** (0.053)
Constant	5.004*** (0.106)	4.929*** (0.094)
Observations	1,000	1,000
R <sup>2</sup>	0.238	0.406
Adjusted R <sup>2</sup>	0.235	0.403
Residual Std. Error	2.240 (df = 996)	1.979 (df = 995)
F Statistic	103.438*** (df = 3; 996)	169.846*** (df = 4; 995)

Note:


\* p<0.1; \*\* p<0.05; \*\*\* p<0.01

## Sin interacción - cuando existe






## Con interacción - cuando existe



## Interpretación de multicolinealidad en diagrama de Ballentine



- El coeficiente  $\beta_j$  mide el efecto de  $X_j$  después de eliminar el efecto de todas las otras  $X$  sobre  $X_i$ . Es decir, el estimador MCO "depura" el efecto de  $X_i$  sobre  $Y$ , al eliminar la redundancia de la información que aportan otras variables.

## **Violaciones de supuestos - endogeneidad**

---


# Temas a considerar

Causalidad:  $X \rightarrow Y$


Causalidad inversa:  $X \leftarrow Y$

Simultaneidad:  $X \leftrightarrow Y$


Variables Omitidas:




# Causalidad inversa




Dilbert.com DilbertCartoonist@gmail.com



2-10-12 © 2012 Scott Adams, Inc. /Dist. by Universal Uclick



## Omitted Variable Bias




$$Y = b_0 + b_1X + e$$

$$Y = \beta_0 + \beta_1X + \beta_2Z + \varepsilon$$

$$b_1 \neq \beta_1$$

## Omitted Variable Bias



$$b_1 \approx A + B$$

$$\beta_1 \approx A$$

$$bias \approx B$$

$$\beta_1 = b_1 - bias \approx (A + B) - B$$